

2. Evidencias del Proceso ETL

Descripción del Pipeline ETL

El motor ETL (`apps/etl/services/etl_engine.py`) procesa el archivo `dataset_clinico_etl_1800_registros.xlsx` que contiene **1800 registros** de pacientes clínicos. El pipeline sigue 3 fases:

Fase 1: EXTRACT (Extracción)

- Lee el archivo Excel usando `pandas.read_excel()`
- Registra metadatos: nombre del archivo, tipo, número de filas extraídas, columnas detectadas
- **Resultado:** DataFrame de Pandas con los datos crudos

Fase 2: TRANSFORM (Transformación)

Aplica 10 pasos de limpieza y transformación:

Paso	Acción	Detalle
1	Normalización de columnas	Elimina tildes de nombres de columnas (Ej: <code>presión_sistólica</code> → <code>presion_sistolica</code>)
2	Eliminación de duplicados	<code>drop_duplicates(subset=['id_paciente'], keep='first')</code>
3	Conversión de edad	<code>pd.to_numeric()</code> con imputación de mediana para valores no numéricos
4	Conversión de presiones	Limpieza de valores no numéricos, imputación con mediana
5	Estandarización de sexo	<code>M, Masculino, Male</code> → <code>M</code> ; <code>F, Femenino, Female</code> → <code>F</code>
6	Normalización de diagnósticos	Corrección ortográfica y unificación de términos médicos
7	Remoción de outliers clínicos	Pesos > 300kg, temperatura <30°C o >42°C, glucosa fuera de rango, etc.
8	Imputación de nulos	Media para glucosa/colesterol/peso/altura; 36.5°C para temperatura; mediana para saturación

9	Cálculo de IMC	$IMC = peso / altura^2$
10	Cálculo de riesgo	Algoritmo basado en umbrales clínicos (presión, glucosa, saturación, IMC, fumador)

Fase 3: LOAD (Carga)

- Elimina registros previos de `PacienteClinico`
- Inserta los datos transformados usando `bulk_create` (inserción optimizada)
- Genera un registro en `RegistroETL` documentando: fecha, usuario, registros procesados, limpios, duplicados eliminados, tiempo de ejecución, estado y errores

Resultados del Procesamiento

Tras ejecutar el ETL sobre el dataset de 1800 registros:

Métrica	Valor
Registros procesados	1800
Registros limpios insertados	1800
Duplicados eliminados	0
Estado	Exitoso
Tiempo de ejecución	Variable (~2-5 segundos)

Capturas de Pantalla (Guía)

Para generar las capturas de pantalla como evidencia visual:

1. Módulo ETL (/etl/)

- Ingresar con usuario `admin` / `Admin1234`
- Navegar a la sección **ETL** en la barra de navegación
- Hacer clic en **"Ejecutar ETL"**
- **Capturar:** El modal de confirmación "Proceso ETL completado con éxito" y la tabla de historial mostrando la ejecución con estado "Exitoso" y 1800 registros

2. Dashboard (/)

- Navegar al Dashboard principal

- **Capturar:** Las 4 tarjetas KPI (Total Pacientes: 1800, Pacientes Críticos, Hipertensos, Diabéticos)
- **Capturar:** Las 3 gráficas (Distribución por Riesgo, por Sexo, por Rangos de Edad)
- **Capturar:** La tabla de "Últimos Pacientes Críticos"

3. Módulo Pacientes (/pacientes/)

- Navegar a la sección **Pacientes**
- **Capturar:** La tabla paginada mostrando los pacientes procesados con su información clínica

4. Exportación de Reportes

- Navegar a la sección **Reportes** (/reportes/)
- **Capturar:** Las tarjetas de estadísticas globales
- Hacer clic en cada botón de exportación (CSV, Excel, PDF)

Reportes Generados

El sistema permite generar reportes en 3 formatos desde la sección Reportes o Pacientes:

1. Reporte CSV (GET /api/reportes/exportar/?formato=csv)

- Archivo de texto plano con todos los campos de pacientes
- Delimitado por comas, con cabecera
- Descargable como `pacientes.csv`

2. Reporte Excel (GET /api/reportes/exportar/?formato=excel)

- Archivo de Excel con los datos completos de pacientes
- Hoja: "Pacientes"
- Descargable como `pacientes.xlsx`

3. Reporte PDF Ejecutivo (GET /api/reportes/exportar/?formato=pdf)

- Documento PDF profesional con:
- Título: "Reporte Ejecutivo de Pacientes Clínicos"
- KPIs principales (Total, Críticos, Hipertensos, Diabéticos, Fumadores, Riesgo Promedio)
- Tabla de últimos 10 pacientes críticos
- Descargable como `reporte_ejecutivo.pdf`

Verificación de Calidad de Datos

El script `backend/verify_etl.py` realiza 10 validaciones automáticas para garantizar la integridad del ETL:

```
# Ejemplo de ejecución
# python manage.py shell < verify_etl.py
|
1. TOTAL REGISTROS EN BD: 1800
2. REGISTROS CON NULOS: 0
3. VALORES DE SEXO: Solo M y F
4. DIAGNOSTICOS CON ERRORES ORTOGRAFICOS:
5. PESO OUTLIERS >300kg: 0
6. TEMPERATURA OUTLIERS <30°C o >42°C: 0
7. IDS DUPLICADOS: 0
```

Evidencia de Ejecución en Servidor

El servidor está corriendo actualmente en:

- **URL:** `http://localhost:8000`
- **Estado:** HTTP 200 OK
- **Puerto:** 8000
- **Base de datos:** SQLite (`backend/db.sqlite3`)